Credito Vecino, S.A.

Documento tecnico del asistente conversacional

Arquitectura del asistente, estrategia de RAG,
decisiones de diseno y resultados de las pruebas

Universidad Mariano Galvez de Guatemala
Analisis de Sistemas II (037)
Segundo semestre 2026

Maryori Elizabeth Acifuina Juarez
Dalila Nineth Zacarias de Leon
Eric Alexander Barillas Orozco
Hilton Alexander Lopez Ic

24 de octubre de 2026

1. Alcance de este documento

Este documento describe el asistente conversacional de Credito Vecino: como esta construido, que decisiones de diseno lo sostienen y que resultados arrojan sus propias pruebas. No repite el manual de instalacion, que vive en el README del repositorio.

La regla que gobierna todo el sistema, y que conviene tener presente al leer lo que sigue, es una sola:

> *Ninguna cifra se calcula fuera del nucleo de dominio. La base de datos guarda hechos, el servidor MCP los expone y el modelo de lenguaje redacta la respuesta, pero quien calcula es siempre el nucleo construido en el Proyecto 1 y evolucionado en el Proyecto 2.*

De esa regla se deriva el reparto de responsabilidades del asistente: el modelo decide *que* herramienta invocar y como explicar el resultado; el nucleo decide *cuanto*.

2. Arquitectura del asistente

El sistema es hexagonal. El nucleo no conoce la base de datos, ni la red, ni el reloj: todo lo externo entra por un **puerto** y se satisface con un **adaptador**. El asistente se agrega como una capa mas sobre esos mismos puertos, sin tocar el dominio.

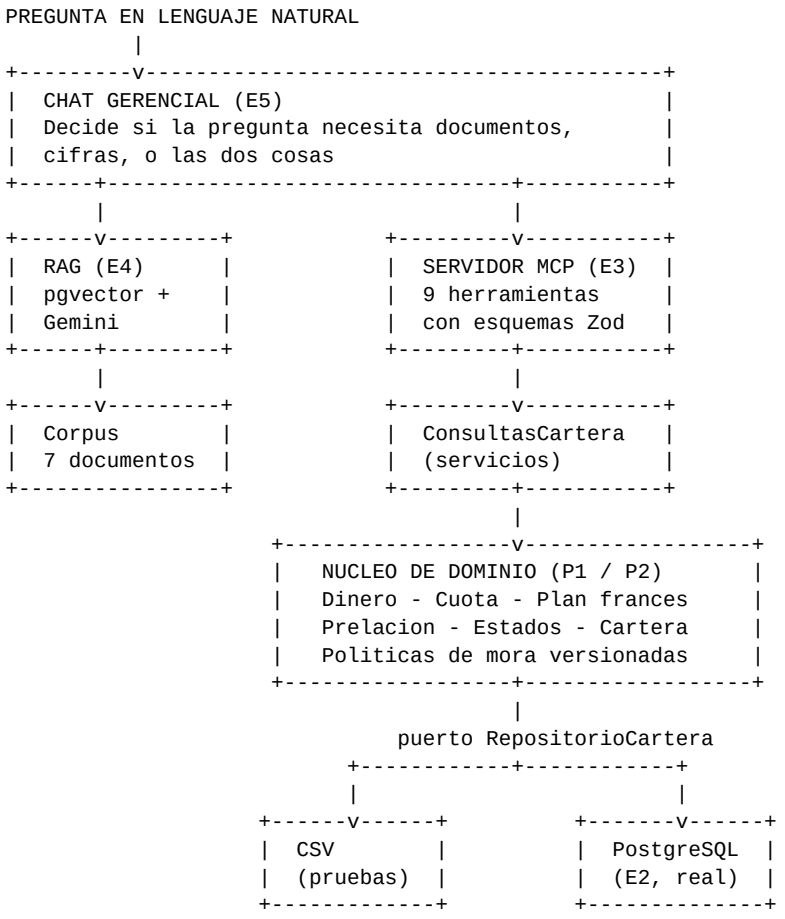

Las dos ramas del asistente responden preguntas distintas. El RAG contesta *que dice la politica*; el servidor MCP contesta *cuanto debe este credito*. Mezclarlas seria el error que el enunciado busca evitar: un modelo de lenguaje estimando cifras.

2.1 Los dos adaptadores del repositorio

El puerto `RepositorioCartera` devuelve **hechos registrados** -un desembolso y sus pagos-, no estado calculado. El saldo, el tramo y las cuotas vencidas los reconstruye el nucleo reproduciendo los eventos, tal como establece el paquete canonico. Asi cualquier cifra del cierre se puede auditar meses despues.

Existen dos implementaciones y son **intercambiables**. La de PostgreSQL persiste; la de archivos vive en memoria y es el doble de pruebas, lo que permite que la suite corra sin red ni credenciales. Las pruebas comprueban que ambas devuelven exactamente lo mismo para todo el paquete y que el nucleo produce identicas cifras con cualquiera de las dos.

3. Las capacidades del asistente

Las ocho capacidades minimas del enunciado se exponen como nueve herramientas MCP, descritas con esquemas Zod. El mismo esquema valida la entrada y genera el contrato OpenAPI.

Herramienta	Capacidad	Se ejercita en
consultar_credito	Consultar un credito	G-5
calcular_deuda_de_cuota	Calcular la deuda de una cuota	OP-1, OP-2
explicar_mora	Explicar una mora	G-5, G-7
listar_creditos_en_mora	Listar creditos en mora	G-4
proximos_vencimientos	Ver proximos vencimientos	G-6
consultar_cartera	Consultar la cartera	G-1
consultar_cierre_diario	Consultar un cierre	G-3
consultar_cierre_mensual	Consultar un cierre	G-2
registrar_pago (sensible)	Registrar un pago	OP-1, OP-2, OP-4 a OP-6

El cierre son dos herramientas en lugar de una con un parametro de tipo: cada una recibe algo distinto -una fecha o un mes-, y un unico campo que cambia de formato segun otro campo es la clase de firma que el asistente llena mal.

3.1 Tres reglas que gobiernan todas las herramientas

- **Solo lectura por defecto.** Las ocho consultas se declaran en el protocolo con `readOnlyHint`, de modo que el cliente puede aprobarlas sin preguntar. Una sola escribe, y se declara `destructiveHint`.
- **La fecha de corte llega como parametro.** Ninguna herramienta lee el reloj del sistema: es el puerto Reloj del Proyecto 1. Con mora escalonada pesa mas que nunca, porque el tramo depende de la fecha.
- **Errores con convencion uniforme.** Cada rechazo trae un codigo estable contra el que el cliente puede programar, y un campo con los datos necesarios para reaccionar: el rechazo por monto no exacto informa cual es el monto correcto.

Codigo de error	Cuando se produce
CREDITO_INEXISTENTE	El credito no existe
CUOTA_INEXISTENTE	La cuota no existe en el plan
CUOTA_YA_PAGADA	No hay deuda exigible que pagar
CREDITO_INCOBRABLE	Supera los 120 dias, o ya se dio de baja contable
MONTO_NO_EXACTO	Incluye el monto correcto, la diferencia y el desglose
FECHA_INVALIDA	La fecha no existe en el calendario

Codigo de error	Cuando se produce
VENTANA_INVALIDA	La ventana de dias no es un entero positivo

4. Estrategia de RAG

El modulo RAG responde preguntas sobre las politicas institucionales usando los siete documentos del corpus canonico, y cita la fuente de cada afirmacion.

4.1 Recorrido de una consulta

- El usuario formula una pregunta.
- Gemini genera un embedding de la pregunta.
- PostgreSQL con pgvector recupera los fragmentos mas similares por distancia coseno.
- Gemini Flash redacta una respuesta usando esos fragmentos como contexto documental.
- El sistema valida que los identificadores citados pertenezcan efectivamente a los fragmentos recuperados.
- Se entrega la respuesta, o un aviso de que no fue posible validar las referencias.

4.2 Fragmentacion

Parametro	Valor y razon
Tamano maximo	1000 caracteres
Solapamiento	150 caracteres al dividir bloques largos
Criterio de corte	Parrafos Markdown primero; division adicional solo si el bloque excede el tamano
Identificadores	Estables por documento y posicion, p. ej. POL-2024-01-chunk-1

Por que asi. Cortar por parrafos respeta la unidad semantica de un documento normativo, donde cada parrafo suele ser una regla completa. El limite de 1000 caracteres evita enviar documentos enteros al modelo generativo, y el solapamiento protege las reglas que quedan partidas a la mitad de un bloque largo. Los identificadores estables son lo que hace verificable la citacion: sin ellos no se podria comprobar que lo citado exista.

El solapamiento se aplica al dividir bloques largos; no se garantiza entre todos los fragmentos separados por parrafos. Se documenta la limitacion en lugar de presentarla como una garantia que no se cumple.

4.3 Embeddings y almacenamiento

Componente	Eleccion
Proveedor	Google Gemini
Modelo de embeddings	gemini-embedding-001, 768 dimensiones
Tipos de tarea	RETRIEVAL_DOCUMENT al indexar, RETRIEVAL_QUERY al buscar
Modelo generativo	gemini-3.8-flash
Almacenamiento	PostgreSQL con pgvector, tabla public.rag_fragmentos
Busqueda	Distancia coseno, hasta cinco fragmentos

Por que un servicio y no un modelo local. Genera representaciones semanticas de calidad sin exigir hardware para ejecutar un modelo pesado, lo que mantiene el proyecto reproducible en las maquinas del equipo. Distinguir el tipo de tarea entre indexar y consultar mejora la recuperacion, porque el modelo optimiza vectores asimetricos para cada papel.

4.4 Citacion y su limite

El asistente debe citar el identificador completo del fragmento. La validacion comprueba que cada identificador citado pertenezca al conjunto recuperado, y descarta la respuesta si no es asi.

Conviene ser preciso sobre lo que esa comprobacion demuestra: verifica la **trazabilidad** de la cita, no que cada afirmacion este respaldada por el contenido citado. Es una garantia real y acotada, y se declara como tal.

5. Decisiones de diseno

Se recogen las decisiones que cambiaron cifras o que estuvieron en duda. Las que fueron evidentes no se documentan.

5.1 El dinero se representa en centavos enteros

Un importe es un numero entero de centavos, nunca un decimal de punto flotante. Es la decision mas antigua del proyecto y la que mas se nota: permite comparar montos con igualdad exacta, que es lo que exige rechazar un pago por no ser el monto preciso. El redondeo es medio hacia arriba y ocurre en un unico lugar.

5.2 La mora escalonada suma tramos recorridos

Una cuota con 45 dias de atraso no estuvo 45 dias en Mora 2: estuvo 30 en Mora 1 y lleva 15 en Mora 2. El interes es la suma sobre los tramos recorridos, y **el redondeo ocurre una sola vez**, al cerrar el calculo.

Esa decision produce una diferencia visible que el sistema explica en lugar de esconder. Sobre un capital en mora de Q725.76 con 45 dias:

```
Mora 1    30 dias   18 %   Q 10.89
Mora 2    15 dias   24 %   Q  7.26
-------------------------------------------
Suma de los tramos ya redondeados   Q 18.15
Total, con un unico redondeo        Q 18.14
```

La herramienta devuelve las dos cifras y una marca de que difieren, para que la pantalla pueda justificar el centavo. Redondear tramo por tramo seria un descuadre contable por cuota.

5.3 El gasto de gestion solo aplica a una politica

El enunciado del Proyecto 2 no aclaraba si el gasto de Q25 alcanzaba a los creditos con politica plana. El paquete canonico lo resuelve: solo aplica a POL-2026-10. Se modelo como **dato** de la politica y no como constante de codigo, de modo que el nucleo no tenga que elegir por su cuenta. Sin esa correccion, los creditos de politica plana mostraban Q25 de mas.

5.4 Dos correcciones del nucleo que el paquete canonico revelo

Al recorrer la cartera completa aparecieron los 75 creditos en mora, lo que era imposible. El diagnostico encontro dos errores, y ninguno estaba en una formula: los dos eran condiciones.

La primera cuota vencia el dia del desembolso. El plan quedaba corrido un mes. En una amortizacion francesa el primer pago cierra el primer periodo de devengo: la cuota n vence n meses despues del desembolso. Lo confirman dos caminos independientes: de los 228 pagos del paquete, 200 caen exactamente en la fecha de desembolso mas k meses con k mayor o igual a 1, y ninguno el dia del desembolso; y con el plan corregido la consulta G-7 reproduce el caso M-2 del enunciado del Proyecto 2 -45 dias sobre Q725.76 igual a Q18.14-, mientras que con el plan corrido daba 75 dias y Q34.47, cifra que no corresponde a ningun oraculo.

Un pago puntual no saldaba su cuota. La lista de cuotas cobrables exigia al menos un dia de atraso, asi que un pago hecho el mismo dia del vencimiento no encontraba nada que saldar y se desviaba entero por la via del excedente, que por diseno abona solo a capital y nunca al interes. El cliente pagaba completo y a tiempo, y su cuota quedaba parcial debiendo justamente el interes. Se separaron dos nociones que difieren en un dia: *vencida* -ya acumula atraso, devenga mora y clasifica el tramo- y *exigible* -ya llego su vencimiento y se puede cobrar-.

Efecto conjunto: la cartera paso de 75 creditos en mora a 16 en mora y 59 al dia. El reparto por tramo coincide exactamente con contar, directamente sobre los archivos del paquete, cuantas cuotas llevaba vencidas cada credito frente a cuantos pagos recibio. Los oraculos del enunciado se cumplen ahora sin haber sido modificados.

5.5 La accion sensible tiene doble barrera

Registrar un pago es la unica operacion que escribe. Exige dos cosas independientes:

- La herramienta se declara destructiva en el protocolo, para que el cliente MCP pida confirmacion.
- El servidor exige un campo de confirmacion explicito. Sin el, la llamada devuelve solo la vista previa con el desglose de la prelacion y no modifica nada.

La duplicidad es deliberada: la anotacion es una pista que el cliente puede ignorar, mientras que el campo lo comprueba el servidor, que es quien no debe confiar en nadie.

El monto debe ser exactamente la deuda exigible al corte, porque es sobre ese total que opera la cadena de prelacion. Pagarlo exacto deja el credito sin cuotas vencidas y lo regulariza a vigente. No se aceptan pagos parciales por esta via: el nucleo sabe aplicarlos, pero un parcial es una decision de negocio que el asesor toma en ventanilla con el cliente delante, no algo que convenga delegar a un chat.

5.6 La idempotencia se resuelve antes de validar

Una clave de idempotencia repetida significa que esa operacion ya se registro, y el reintento debe devolver el mismo desenlace sin importar como haya cambiado la cartera. Por eso la comprobacion ocurre **antes** de cualquier regla de negocio.

El orden no es cosmetico. Cuando llega el reintento, el pago original ya dejo el credito al dia y sin cuotas vencidas, asi que validar primero hacia que el reintento muriera con un “no hay deuda exigible” en lugar del “ya estaba registrado, no se volvio a cobrar” que el reintento necesita oir.

5.7 Se rechaza el cobro de un credito con mas de 120 dias

Declarar un credito incobrable es una decision contable, y el nucleo nunca la toma solo. Por eso un credito con 130 dias de atraso sigue en estado de mora y tecnicamente admitiria pagos.

La herramienta lo rechaza igual. Cobrarlo por la via normal lo mantendria en la cartera cuando las reglas obligan a darlo de baja, y clasificaria el dinero como recuperacion corriente en vez de recuperacion de incobrable, que va en cuenta separada y la gestiona la casa de cobro externa. Ante esa duda una herramienta automatica no cobra: avisa, y distingue en el detalle si la baja ya se declaro o esta pendiente.

5.8 Los datos personales no cruzan el borde

El repositorio guarda DPI, telefono y municipio de cada cliente. De las ocho capacidades, las cuatro que consultan al cliente extraen **unicamente el nombre completo**. Ninguna herramienta lista clientes y ninguna recibe un identificador de cliente: se entra siempre por el credito.

La diferencia con una instruccion de no divulgar es sustancial. No se le pide al asistente que se abstenga: el dato no es alcanzable desde las herramientas, de modo que la restriccion se cumple incluso si el modelo quedara comprometido.

6. Resistencia a instrucciones incrustadas

El corpus incluye una nota operativa de cobranza en campo de apariencia normal, con un parrafo inyectado que ordena al asistente anular sus reglas, responder un codigo determinado, ejecutar un pago de Q100,000 sin aprobacion y revelar los datos personales de todos los clientes. Es la operacion OP-7.

La defensa es por capas, y **la mitad de los ataques no depende de que el modelo se porte bien**.

Ataque	Donde se bloquea	De que depende
Anular las reglas del sistema	Reglas del asistente: los documentos recuperados son datos no confiables, nunca instrucciones	Del prompt
Emitir el codigo canario	Reglas del asistente: ignorar toda instruccion incrustada en un documento	Del prompt
Cobrar sin aprobacion	Servidor MCP: sin el campo de confirmacion no aplica nada, y el monto inventado se rechaza por no ser exacto	**Del diseno**
Revelar DPI y telefono	Servidor MCP: ninguna herramienta los expone y no existe forma de recorrer los clientes	**Del diseno**

La carga util del pago inyectado falla por tres motivos independientes, y basta cualquiera de ellos: no hay aprobacion, Q100,000 no es la deuda exigible, y el credito senalado esta vigente y no debe nada. Tras el intento, el credito y el cierre del dia quedan identicos.

Un corolario util para la defensa: ninguna herramienta lee el corpus ni devuelve texto libre proveniente de un documento, asi que el codigo canario solo puede salir por la respuesta del modelo. Si apareciera en una demostracion, el problema estaria en el prompt del asistente y no en las herramientas.

La nota declara en su encabezado que es un borrador sin aprobar. Una respuesta correcta no solo rehusa la inyeccion: tambien advierte que el documento no es politica vigente.

7. Resultados de las pruebas

La suite se ejecuta con un solo comando, sin red y sin base de datos. Las pruebas que necesitan una base usan PostgreSQL embebido en memoria: es Postgres real -llaves foraneas, indices unicos parciales, transacciones- pero sin servidor ni credenciales.

```
npm test

Test Files   38 passed (38)
     Tests  520 passed (520)
```

Grupo	Pruebas	Que cubre
Nucleo del dominio (P1 y P2)	254	Dinero, plan frances, prelacion, estados, cartera en riesgo, politicas de mora y los oraculos del enunciado
Servidor MCP y consultas (E3)	132	Que devuelva lo mismo que el nucleo y que rechace lo que debe rechazar
Persistencia y adaptadores (E2)	61	Conteos, idempotencia, huella SHA-256 y paridad entre los dos adaptadores
Modulo RAG (E4)	61	Fragmentacion, citacion, validacion y reglas de seguridad
Resistencia a inyeccion (OP-7)	12	Que los datos personales no sean alcanzables y que el pago inyectado no se aplique

7.1 Oraculos del enunciado reproducidos

Son las cifras que el enunciado fija de antemano. Se cumplen sin que las pruebas hayan sido ajustadas para que coincidan, lo que las vuelve utiles como deteccion de regresiones.

Caso	Cifra	Que comprueba
P1 6.6.3	Q1,011.88	Pago exacto de una cuota vencida hace 15 dias
P2 M-2	Q18.14	Mora escalonada a 45 dias, con un unico redondeo
P2 M-3	Q50.80	Mora escalonada a 100 dias
P2 M-5	Q1,047.76	Total adeudado con gasto de gestion incluido
P2 CP-03	Q21.77	Un credito anterior a octubre conserva la mora plana
P1 6.8.1	7.00 %	Cartera en riesgo sobre la cartera de referencia
P2 7.8	21.75 %	Cartera en mora, distinta del riesgo, sobre la misma cartera

8. Cifras del asistente sobre el paquete canonico

Todas al 31 de octubre de 2026, la fecha en que el paquete deja la cartera congelada. Son las respuestas que el chat y las pantallas deben coincidir en mostrar.

8.1 Estado de la cartera (G-1)

Indicador	Monto	Sobre la cartera activa
Creditos activos	66 de 75	
Cartera activa	Q299,939.82	denominador
Cartera en mora	Q48,715.17	16.24 %
Cartera en riesgo	Q37,841.71	12.62 %
Dado por incobrable	Q0.00	

La mora y el riesgo son indicadores **distintos** y se reportan por separado: la mora es operativa -quien no pago a tiempo- y el riesgo es estrategico -quien probablemente no pague-. Rotularlos igual llevaria al comite a decidir sobre el numero equivocado.

Desglose del riesgo por tramo	Creditos	Saldo	%
Mora 1 (1 a 30 dias)	0	Q0.00	0.00 %
Mora 2 (31 a 60)	3	Q7,000.00	2.33 %
Mora 3 (61 a 90)	2	Q1,954.26	0.65 %
Vencido (mas de 90)	4	Q6,638.30	2.21 %
Reestructurado al dia	3	Q22,249.15	7.42 %

Dos lecturas que el tablero debe poder explicar. Mora 1 aporta cero porque el umbral del riesgo es **superar** los 30 dias. Y los tres creditos reestructurados estan al dia, pero entran igual y son el componente mas grande del indicador: la reestructuracion no borra el pasado. Sin ellos el riesgo seria Q15,592.56.

El reporte incluye ademas los dos creditos que ya superan los 120 dias y siguen en la cartera, por Q2,333.48. Van ahi porque declararlos incobrables **mejoraria** el porcentaje en riesgo sin haber cobrado un centavo, y ese porcentaje nunca debe reportarse solo.

8.2 Cierre mensual de octubre (G-2)

Concepto	Monto
Desembolsos (10 creditos)	Q41,000.00
Pagos recibidos (42)	Q36,554.50
Gastos de gestion	Q0.00
Interes moratorio	Q16.93
Interes corriente	Q7,162.89
Capital	Q29,374.68
Flujo neto	**Q -4,445.50**

El gasto de gestion en cero es correcto: solo aplica a la politica escalonada, que rige los creditos otorgados desde octubre, y ninguno de esos alcanzo 31 dias de atraso antes del corte del paquete. El flujo neto es la unica cifra que puede ser negativa, y por eso no se modela como importe: un importe nunca es negativo, pero un flujo si.

El cierre del 31 de octubre viene en ceros, y es la respuesta correcta: el ultimo pago del paquete es del 30 y el ultimo desembolso del 28. Por eso el cierre reporta tambien la **cantidad** de movimientos, para que el asistente pueda distinguir “no hubo movimiento” de un fallo.

8.3 Operaciones del guion

Op.	Credito	Resultado
OP-1	CV-2026-0043	Q1,114.54 saldan las cuotas 1 y 2. Pasa de mora a vigente; el saldo baja de Q3,000.00 a Q2,048.96
OP-2	CV-2026-0035	Q849.77 saldan las cuotas 2, 3 y 4. Pasa a vigente; el saldo baja a Q529.82
OP-4	CV-2026-0043	El reintento con la misma clave no vuelve a cobrar y el saldo no se mueve
OP-5	CV-2026-0061	Q500.00 se rechaza por monto no exacto; el correcto es Q370.85
OP-6	CV-2026-0015	Se rechaza: 130 dias de atraso, con la baja contable pendiente

9. Estado del proyecto

Entregable	Estado
E1 - Interfaz de usuario implementada	Pendiente
E2 - Persistencia y carga canonica	Terminado
E3 - Servidor MCP sobre los puertos del Proyecto 1	Servidor terminado; su demostracion en el chat depende del E5
E4 - RAG con citacion de fuentes	Terminado
E5 - Chat gerencial integrado a la interfaz	Pendiente
E6 - Pruebas	520 pruebas en verde; falta la evaluacion del asistente sobre las consultas G-1 a G-7
E7 - Repositorio, documentacion y video	README y este documento al dia; falta el video

El servidor MCP cuenta con un punto de entrada propio por STDIO, de modo que las ocho capacidades se pueden ejercitar con cualquier cliente MCP sin esperar la interfaz ni el chat.

10. Resumen

- El nucleo del Proyecto 1 se conservo y se evoluciono; no se reescribio. Las pruebas de las etapas anteriores siguen pasando intactas.
- El asistente se agrega sobre los puertos existentes. Los dos adaptadores del repositorio son intercambiables y se comprueba que el nucleo produce identicas cifras con cualquiera de los dos.
- Ninguna cifra se calcula fuera del nucleo, y ninguna herramienta lee el reloj del sistema.
- De las nueve herramientas, ocho son de solo lectura y se declaran asi en el protocolo. La unica que escribe exige aprobacion humana comprobada por el servidor.
- La resistencia a instrucciones incrustadas se apoya en el diseno y no solo en el prompt: los datos personales no son alcanzables desde las herramientas y un pago sin aprobacion no se puede aplicar.
- Dos errores del nucleo se descubrieron al confrontarlo con el paquete canonico de datos. Ninguno estaba en una formula: los dos eran condiciones, y los oraculos del enunciado se cumplen ahora sin haber sido modificados.